

VL-MoE 推理优化整体研究框架

从真实推理负载出发，围绕视觉前端与专家调度两个瓶颈展开协同优化

第2章

负载分析与问题建模

现象：图像 Token 占比高，Visual Encoder 前端开销显著；专家路由存在跨层可预测相关性

目标：在任务效果稳定与 GPU cache 受限条件下，降低 TTFT / latency

第3章

视觉侧优化

文本语义引导视觉 Token 打分

基于语义熵自适应确定保留比例

Stage 1 / Stage 2 拆分，并与文本侧计算 overlap

目标：降低 Visual Encoder 可见耗时和 TTFT

优化路径 A：压缩视觉前端开销

第4章

专家侧优化

重新采集 Qwen3-VL fresh routing trace

训练 layer-0 条件化全局专家预测器

置信度过滤、层距衰减与预算约束的受限预取调度

目标：提前加载高概率专家，减少同步等待

优化路径 B：降低专家搬运等待

系统

原型系统实现

SAT-ToMe 模块、双流视觉流水

全局预测器与 expert cache 调度器

第5章

实验评估

任务效果保持性、TTFT 与前端耗时

预测 recall、真实 CPU-GPU offload 微基准

核心结果：任务分数保持 0.995+ | Visual Encoder 可见耗时 8572ms→800ms | 全局预测 mean recall 0.7219 | 最终 offload 配置约 2.53× 加速